

Documentatie Proiect Speech to Text using Azure AI Services

Student: Rus Rebeca-Emanuela

eMail: rebecaemanuelarus@gmail.com

Cuprins

1. Stadiul actual

1.1. Overview

1.2. Exemple de Aplicații Speech-to-Text

1.3. Proiectul meu

2. Fundamentare teoretică

3. Implementare practică

3.1. Etapele implementării practice

3.2. Adăugarea de opțiuni suplimentare

4. Rezultate experimentale

5. Concluzii

6. Bibliografie

1. Stadiul actual

1.1. Overview

Tehnologia Speech-to-Text a devenit o componentă esențială în transformarea modului în care interacționăm cu dispozitivele și software-ul. Aplicațiile Speech-to-Text permit transcrierea automată a vorbirii umane în text, facilitând accesibilitatea, automatizarea și eficiența în diverse domenii. Aceste aplicații utilizează algoritmi de procesare a limbajului natural (NLP) și inteligență artificială (AI) pentru a interpreta, transcrie și înțelege vorbirea. [1]

Această tehnologie este utilizată pe scară largă în prezent și cuprinde o gamă largă de domenii, precum:

- **Asistență Virtuală și Control Vocal:** asistenți personali virtuali precum Siri (pentru dispozitive Apple), Google Assistant, Alexa (oferit de Amazon), și Cortana (oferit de Microsoft) utilizează tehnologii Speech-to-Text pentru a recepționa comenzile utilizatorilor și a răspunde în timp real. Aceste aplicații permit utilizatorilor să controleze dispozitivele inteligente, să seteze note cu scopul de a aminti anumite aspecte importante sau să caute informații online prin comenzi vocale. [2]
- **Educație și Cercetare:** tehnologia Speech-to-Text este folosită pentru a transcrie lecții sau seminarii în timp real, oferind accesibilitate pentru studenții cu dizabilități auditive. Aplicațiile precum Otter.ai și Rev transcriu automat interviuri, ședințe sau conferințe, accelerând procesele de analiză și documentare. [2]
- **Medicină și Sănătate:** tehnologia Speech-to-Text este integrată în sistemele de gestionare a înregistrărilor medicale pentru a permite medicilor să dicteze notele pacientului. Exemple includ **Nuance Dragon Medical One** și **M*Modal Fluency Direct**. Această soluție reduce semnificativ timpul necesar documentării și permite medicilor să se concentreze mai mult pe pacienți. [2]
- **Industria Legală și Jurnalism:** aplicațiile Speech-to-Text automatizează transcrierea înregistrărilor proceselor, interviurilor și mărturiilor. Exemple includ **Verbit** și **Sonix**. Jurnaliștii folosesc soluții Speech-to-Text pentru a transcrie interviuri și conferințe de presă, accelerând procesul de creare a conținutului. [2]
- **Accesibilitate:** persoanele cu dizabilități auditive sau motorii beneficiază de transcrieri în timp real pentru conversații, ședințe sau utilizarea dispozitivelor. Aplicații precum **Live Transcribe** (asigurată de Google) oferă transcrieri instantanee pentru a sprijini comunicarea. [2]

În consecință, aplicațiile Speech-to-Text sunt deja omniprezente în multe domenii și continuă să redefinească modul în care lucrăm, comunicăm și interacționăm cu tehnologia. [2]

În plus, aplicațiile care se bazează pe tehnologia Speech-to-Text au anumite avantaje, dar și anumite limitări. Astfel, în continuare o să prezint unele avantaje și limitări ale aplicațiilor ce utilizează această tehnologie.

Avantajele esențiale ale aplicațiilor ce folosesc tehnologia Speech-to-Text sunt următoarele:

- + **Eficiență și economisirea timpului:** acestea elimină necesitatea de a transcrie manual fișiere audio sau video.

- + **Accesibilitate:** se îmbunătățește comunicarea pentru persoanele cu dizabilități auditive.
- + **Personalizare:** modelele de AI pot fi antrenate pentru a recunoaște vocabular specific unei industrii sau organizații.
- + **Multilingvism:** acestea suportă numeroase limbi și dialecte, facilitând utilizarea globală. [3]

Principalele limitări ale aplicațiilor ce utilizează tehnologia Speech-to-Text sunt următoarele:

- **Precizia:** factori precum zgomotul de fundal, accentele regionale și viteza vorbirii pot afecta acuratețea transcrierii.
- **Costuri:** unele soluții comerciale, în special cele avansate, pot fi costisitoare pentru utilizatorii individuali.
- **Confidențialitate:** utilizarea serviciilor cloud implică riscuri privind securitatea datelor. [3]

Tehnologia Speech-to-Text continuă să evolueze prin îmbunătățirea algoritmilor de inteligență artificială și utilizarea rețelelor neuronale. Astfel, se anticipează următoarele progrese:

- Îmbunătățirea preciziei pentru limbile mai puțin utilizate.
- Recunoaștere mai bună a emoțiilor și a contextului în vorbire.
- Integrare extinsă cu tehnologii emergente, cum ar fi realitatea augmentată (AR) și internetul lucrurilor (IoT). [1]

1.2. Exemple de aplicații Speech-to-Text

În continuare, o să descriu succint câteva exemple de aplicații de tipul Speech-to-Text. Cele mai cunoscute aplicații de acest tip sunt:

- **Microsoft Azure Speech-to-Text:** acesta oferă servicii de transcriere în timp real sau batch transcription pentru audio și video și permite integrarea cu alte servicii Azure. De asemenea, suportă mai multe limbi și permite personalizarea modelelor de limbaj și a vocabularelor specifice de recunoaștere pentru a îmbunătăți precizia. Este utilizat în general în mediul de afaceri pentru analiza ședințelor sau pentru procese automate. Suplimentar, dispune de API robust pentru integrare. [4]
- **Google Speech-to-Text:** acesta oferă soluții rapide și scalabile, cu suport pentru peste 125 de limbi. Totodată, include funcții avansate, precum: adaptarea la zgomot de fundal și accente, identificarea vorbitorilor și transcrierea în timp real a fișierelor audio lungi. Este integrat în produsele Google Workspace, cum ar fi Google Meet. [5]
- **Amazon Transcribe:** aceasta oferă suport pentru transcriere multilingvă și identificarea vorbitorilor și prezintă capacitatea de a gestiona zgomotul de fundal. În plus, aplicația generează punctuație automată și dispune de modele personalizate pentru specificul industriei. De asemenea, permite identificarea automată a limbii sau a vorbitorului. Această aplicație este folosită pentru analizarea conversațiilor, crearea subtitrărilor pentru videoclipuri sau automatizarea serviciilor pentru clienți. [6]
- **Nuance Dragon NaturallySpeaking:** aceasta reprezintă o soluție populară pentru dictare și transcriere personală și este utilizată pe scară largă de profesioniști din

domeniul sănătății și afacerilor pentru eficiență sporită. Suplimentar, această aplicație dispune de adaptare personalizată la vocea utilizatorului și de utilizare offline, fără dependență de cloud. [7]

- **Otter.ai:** acesta este destinat transcrierii ședințelor și interviurilor și oferă funcții avansate de colaborare, cum ar fi: identificarea automată a participanților, sincronizare text-audio și editor colaborativ și generare de rezumate automate. Această aplicație permite integrarea cu platforme precum Zoom și Google Meet. [8]
- **Sonix.ai:** această aplicație este potrivită pentru profesioniști care lucrează cu conținut audio/video, precum jurnaliști, cercetători sau creatori de conținut, deoarece transformă fișiere audio și video în text în câteva minute și oferă suport pentru peste 40 de limbi. În plus, aceasta dispune de caracteristici avansate, precum: ajustarea transcrierii direct în aplicație, sincronizată cu audio/video, salvarea transcrierilor în diverse formate, cum ar fi Word, PDF, SRT. De asemenea, aceasta detectează și etichetează automat diferiții participanți dintr-o conversație și permite căutarea rapidă în transcrieri. Este compatibilă cu aplicații precum Zoom, Dropbox, și Google Drive. [9]
- **Verbit:** aceasta este o aplicație avansată de Text-to-Speech și transcriere automată, concepută pentru medii profesionale și academice, în special în educație, justiție, și afaceri. Această aplicație utilizează inteligența artificială combinată cu verificarea umană pentru acuratețe ridicată și oferă suport pentru mai multe limbi și accente. De asemenea, aceasta etichetează automat participanții la conversație și permite editarea transcrierilor sincronizate cu înregistrările. Suplimentar, dispune de posibilitatea de generare rapidă de subtitrări pentru evenimente live și conținut video și de adăugarea de termeni specifici industriei. Este compatibilă cu Zoom, Blackboard, și alte sisteme educaționale sau corporative. [10]
- **Vatis.tech:** aceasta este o aplicație de Text-to-Speech și transcriere automată cu caracteristici optimizate pentru limba română și alte limbi, care dispune de modele specializate pentru domeniul medical, juridic și jurnalistic. Aceasta transformă fișiere audio și video în text într-un timp scurt și utilizează algoritmi optimizați pentru limbaje și accente regionale, cu focus pe limba română. De asemenea, și această aplicație dispune de un editor de text sincronizat cu fișierele audio pentru ajustări rapide și permite salvarea transcrierilor în formate populare, precum Word, SRT, TXT. În plus, aplicația recunoaște și separă diferiți participanți dintr-o conversație și dispune de funcționalități API pentru o integrare ușoară în alte aplicații și fluxuri de lucru. [11]

1.3. Proiectul meu

Acest proiect este dezvoltat folosind limbajul Python și folosește **Azure Speech SDK** pentru transcrierea unui fișier audio în text, cu limbaj specificat ca engleză, respectiv română. Funcționalitățile oferite de această aplicație sunt următoarele:

- ❖ **Recunoaștere Speech-to-Text:** aplicația transformă vorbirea dintr-un fișier audio în text, utilizând serviciul Azure Speech.
- ❖ **Configurare prin variabile de mediu:** aplicația folosește variabile de mediu pentru a autentifica accesul la resursa Azure Speech utilizată. Aceasta permite securitate și flexibilitate.
- ❖ **Limbaj specific:** aceasta este configurată pentru recunoașterea limbii engleze, respectiv a limbii române.
- ❖ **Prelucrarea input-ului audio:** aplicația permite procesarea input-ului preluat fie direct de la microfon, fie dintr-un fișier audio de tip .wav.

- ❖ **Gestionarea rezultatelor:** aplicația gestionează trei posibile cazuri și returnează diferite mesaje specifice, astfel:
 - **Cazuri reușite:** dacă vorbirea este recunoscută, textul transcris este afișat în consolă.
 - **Cazuri fără potrivire:** dacă nu se poate recunoaște vorbirea, este furnizat un mesaj specific.
 - **Cazuri de eroare:** dacă procesul este anulat sau apar erori, spre exemplu configurare incorectă, atunci sunt afișate detalii despre eroare pentru depanare. [12]

În consecință, această aplicație este utilă pentru transcrierea automată a vorbirii în text, fiind ideală pentru procese precum analiza discursului, transcrieri profesionale, sau integrarea în alte soluții bazate pe recunoașterea vocală.

2. Fundamentare teoretică

Procesul Speech-to-Text este unul complex și constă în mai multe etape, precum:

- **Capturarea și Prelucrarea Semnalului Audio:** semnalul audio poate fi captat folosind un microfon, fie integrat într-un dispozitiv, fie extern sau poate fi preluat dintr-un fișier preînregistrat, cum ar fi fișiere de tip .wav sau .mp3. Semnalul astfel capturat este prelucrat pentru a elimina zgomotul de fundal, eco-ul și alte interferențe care pot afecta recunoașterea vorbirii. Algoritmii de procesare audio normalizează volumul și identifică frecvențele relevante pentru vorbirea umană. [13]
- **Segmentarea și Analiza Spectrală:** semnalul audio prelucrat este transformat într-o formă pe care sistemul o poate analiza, folosind segmentarea temporală și transformarea spectrală. În etapa de segmentare temporală fluxul audio este împărțit în segmente mici, de obicei de ordinul milisecundelor. Acest proces ajută la identificarea începutului și sfârșitului fiecărei foneme. În etapa de Analiză spectrală semnalul temporal este convertit într-o reprezentare spectrală utilizând tehnici precum **Transformata Fourier** sau **Transformata Wavelet**. Analiza spectrului permite identificarea caracteristicilor acustice ale sunetului, cum ar fi: frecvență, amplitudine. [13]
- **Decodificarea Sunetelor în Foneme:** fonemele sunt unități fundamentale de sunet din limbaj. Recunoașterea fonetică are loc prin compararea spectrului audio cu modele fonetice predefinite, pentru a identifica **fonemele**. Modelele fonetice sunt specific configurate pentru fiecare limbă, luând în considerare accentele și variațiile regionale. Astfel, sistemele Speech-to-Text utilizează modele acustice antrenate pe seturi mari de date audio pentru a învăța cum să atribuie caracteristicile spectrale la foneme. [13]
- **Reconstrucția Cuvintelor:** odată identificate fonemele, acestea sunt combinate pentru a forma cuvinte utilizând modele de limbaj. Modelele de limbaj folosesc probabilități statistice pentru a prezice cuvintele cel mai probabil în funcție de context. De exemplu, în propoziția „Mă duc la...”, sistemul va considera „școală” mai probabil decât „șoarece”. Pasul următor este contextualizarea: în acest pas cuvintele sunt ajustate în funcție de structura gramaticală și contextul semantic. Astfel, algoritmii pot corecta greșeli cauzate de confuzii fonetice, cum ar fi diferențierea între cuvintele omonime. [13]

- **Transcrierea și Postprocesarea Textului:** rezultatul final al sistemului este o transcriere brută, care poate fi ajustată ulterior. În această etapă se realizează corectarea greșelilor, prin aplicarea unor filtre pentru a corecta greșelile comune, cum ar fi: înlocuirea cifrelor cu litere sau eliminarea cuvintelor repetitive și formatarea textului: textul transcris este formatat conform nevoilor utilizatorului, adăugând spații, punctuație sau marcaje temporale. Suplimentar, unele sisteme permit adăugarea de funcționalități avansate, cum ar fi: identificarea vorbitorilor sau transcrierea multilingvă. [13]
- **Livrarea Rezultatelor:** rezultatul final este livrat utilizatorului, fie ca text brut, fie într-un format specific, precum: subtitrări, fișiere JSON sau XML). Acesta poate fi utilizat pentru diverse aplicații, cum ar fi:
 - **Documentație:** Crearea de transcrieri pentru întâlniri sau interviuri.
 - **Accesibilitate:** Generarea de subtitrări pentru persoanele cu dizabilități auditive.
 - **Analiză de Date:** Extracția automată de informații din discursuri sau conversații. [13]

Bineînțeles, ca orice prelucrare de semnal, și acest proces are limitări. Principalele limitări ale acestui proces sunt:

- ➔ **Zgomotul de Fundal:** afectează calitatea transcrierii.
- ➔ **Accente și Dialecte:** pot necesita modele dedicate pentru recunoaștere corectă.
- ➔ **Limba Ambiguu:** contextul poate fi dificil de interpretat pentru algoritmi. [13]

De asemenea, sistemele Speech-to-Text moderne se bazează pe următoarele tehnologii:

- **Rețele Neuronale Profunde (DNN):** sunt utilizate pentru a antrena modele acustice și lingvistice.
- **Procesare în Cloud:** platforme precum Azure, Google Cloud Speech API și Amazon Transcribe oferă putere de procesare scalabilă pentru aplicații Speech-to-Text.
- **Personalizarea Modelelor:** permite utilizatorilor să adapteze modelele pentru vocabular specific, precum termeni tehnici sau nume proprii. [13]

Astfel, procesul Speech-to-Text este un flux complex care combină prelucrarea semnalelor audio cu inteligența artificială pentru a oferi rezultate precise și utile. Această tehnologie continuă să se dezvolte, reducând limitările și extinzând aplicațiile practice.

3. Implementare practică

Acest proiect este dezvoltat folosind mediul de programare Visual Studio 2022, prin intermediul limbajului Python și folosește **Azure Speech SDK** pentru transcrierea unui fișier audio în text, cu limbaj specificat ca engleză, respectiv română.

Pentru implementarea practică a acestei aplicații am avut ca punct de pornire pagina denumită „**Quickstart: Recognize and convert speech to text**” a site-ului web corespunzător platformei **Azure-AI Services**. [12]

Implementarea propriu-zisă a acestei aplicații a constat în mai multe etape de pregătire a aplicației. În continuare, o să descriu pașii necesari implementării practice a aplicației.

3.1. Etapele implementării practice

Etapele principale necesare implementării practice a aplicației sunt următoarele: pregătirea resursei Azure Speech, instalarea mediului necesar, configurarea mediului, crearea Aplicației, adăugarea unor opțiuni suplimentare și verificarea aplicației.

În continuare, o să dezvolt aceste etape prin explicații concrete:

- **Pregătirea resursei Azure Speech:** pentru a putea crea resursa Azure Speech am fost nevoită să îmi creez un cont gratuit pe portalul Azure, utilizând contul de student oferit de facultate. În continuare, pentru a crea resursa de tip Speech am accesat portalul Azure folosind contul creat, am creat propriu-zis resursa Speech, folosind opțiunea „Create a resource” și căutând cuvântul-cheie „Speech”. Ulterior, am completat detaliile resursei: am ales tipul de abonament Azure (abonament gratuit) și am selectat opțiunea ”Free Trial”. În continuare, am creat un grup de resurse (Resource Group) nou apăsând pe opțiunea ”Create new”. Un grup de resurse este un container logic care organizează resursele Azure asociate. Pentru a crea noul grup de resurse, am ales o regiune propiată de locația mea, în acest caz am ales ” **West Europe**” - pentru Europa de Vest și am introdus un nume unic pentru resursa mea de tip Speech. Ca ultim pas în crearea resursei, am selectat planul de tarifyare dorit, în acest caz: ”Free (F0)”; acest plan dispune de 5 ore de transcriere gratuite pe lună, apoi am apăsă butonul „Review + Create”. După crearea resursei, am navigat la secțiunea ”**Go to Resource**” pentru a accesa resursa Speech creată, iar din meniul din stânga am selectat opțiunea „**Keys and Endpoint**” pentru a obține **cheia (Speech Key)** și **regiunea (Speech Region)**: valorile obținute vor fi utilizate în implementarea codului. [14]
- **Instalarea mediului necesar:** pentru acest proiect am avut nevoie de mediul de programare Visual Studio, versiunea 2022, pe care am instalat-o de pe site-ul oficial ”Microsoft Visual” și am ales pachetul ” Microsoft Visual C++ Redistributable” disponibil pentru sistemul de operare Windows. Ca limbaj, am folosit Python și a fost nevoie de o versiune de Python 3.7 sau mai nouă, astfel am ales să folosesc versiunea de Python 3.12, pe care am descărcat-o de pe site-ul oficial ”Python” și am instalat-o. [12]
- **Configurarea mediului:** pentru început a fost nevoie să mă asigur că am instalat bibliotecile necesare. Astfel, am instalat pachetul Azure Speech SDK: în terminal (command prompt) am rulat următoarea comandă: ” pip install azure-cognitiveservices-speech”. În continuare, am setat variabilele de mediu, determinate în etapa de creare a resursei mele Azure Speech: am configurat variabilele de mediu pentru **cheie (Speech Key)** și pentru **regiune (Speech Region)**, rulând în terminal următoarele comenzi pentru mediul de operare Windows: ” setx SPEECH_KEY <cheia-mea>” (pentru cheie) și ”setx SPEECH_REGION <regiunea-mea>” (pentru regiune); aceste comenzi diferă în funcție de mediul de operare. Aceste variabile sunt necesare pentru a autentifica aplicația. După setarea variabilelor, am verificat dacă acestea au fost adăugate corect folosind comenzile specifice mediului de operare Windows: ” echo %SPEECH_KEY%” și ”echo %SPEECH_REGION%”, iar cheia și regiunea au fost afișate corespunzător în terminal, astfel că valorile de mediu au fost setate corect. În continuare, am repornit mediul de lucru Visual Studio 2022 pentru ca

noile variabile de mediu setate să fie vizibile.. Pentru a verifica dacă resursa funcționează corect, am deschis un terminal și am rulat comanda de test: `"curl -XPOST"https://my_region.api.cognitive.microsoft.com/speechtotext/v3.1/transcriptions -H "Ocp-Apim-Subscription-Key: cheia_mea"` ", iar răspunsul primit nu a conținut erori, ceea ce înseamnă că resursa a fost configurată corect. [12]

- **Crearea Aplicației:** am creat un folder pentru acest proiect, urmând să deschid un terminal în folderul respectiv pentru a crea un fișier cu extensia `".py"`, denumit `"speech_recognition.py"`. Pentru a crea noul fișier în folderul dorit, în terminalul deschis în acel folder am rulat comanda specifică sistemului de operare Windows: `"echo. > speech_recognition.py"`; această comandă diferă în funcție de sistemul de operare utilizat. În fișierul astfel creat am inserat codul oferit de pagina denumită **„Quickstart: Recognize and convert speech to text”** a site-ului web corespunzător platformei **Azure-AI Services**. [12]
- **Rularea Aplicației:** pentru a rula aplicația, am deschis un terminal în folderul în care am creat și am salvat fișierul denumit `"speech_recognition.py"` și am rulat comanda: `"python speech_recognition.py"`, urmând ca în terminal să apară mesajul `"Speak into your microphone."`, ceea ce înseamnă că aplicația a rulat fără erori. [12]

3.2. Adăugarea de opțiuni suplimentare

Pentru a îmbunătăți aplicația, am adăugat unele opțiuni suplimentare. Aceste opțiuni suplimentare sunt următoarele: am extins aplicația concepută pentru a transcrie fișiere audio în limba engleză și pentru fișiere audio în limba română și am adăugat opțiunea de a transcrie semnal audio dintr-un fișier audio cu extensia `".wav"`, nu doar semnalul audio preluat de la microfon.

Posibilitatea de a schimba limba în care aplicația face transcrierea din engleză în română este datorată flexibilității și suportului oferit de **Azure Cognitive Services Speech-to-Text SDK** pentru multiple limbi și dialecte. Aceasta funcționează prin utilizarea unor modele avansate de recunoaștere a vorbirii, care au fost antrenate să înțeleagă și să transcrie corect o gamă largă de limbi și dialecte, precum: franceză, spaniolă, italiană, portugheză, rusă germană, japoneză, greacă, chineză, thailandeză, hindi și multe altele. Azure Speech SDK utilizează coduri de limbă standardizate internațional, spre exemplu: `en-US`, `ro-RO`, `fr-FR`), ceea ce permite o compatibilitate și interoperabilitate ridicată între sisteme. [15] Pentru a schimba limba recunoașterii semnalului audio, respectiv a transcrierii semnalului respectiv, din engleză în română, am modificat următoarea linie de cod: `"speech_config.speech_recognition_language = "es-ES" "` și am transmis ca parametru de limbă: `"ro-RO"`, astfel: `"speech_config.speech_recognition_language = "ro-RO"`. Azure Speech-to-Text oferă suport pentru **limba română** printr-un model de recunoaștere vocală specific limbii. Acest model este antrenat cu date lingvistice și acustice românești pentru a asigura o transcriere precisă. [12]

Pentru a adăuga opțiunea de a transcrie semnal audio dintr-un fișier audio cu extensia `".wav"`, am adăugat următoarea linie de cod: `"audio_config = speechsdk.audio.AudioConfig(filename="MyAudioFile.wav") "`, unde `"MyAudioFile.wav"` reprezintă numele fișierului ce conține semnalul audio pentru care se dorește să se realizeze transcrierea. [12] Pentru a folosi Audacity, am descărcat și am instalat Audacity: acesta este gratuit și ușor de folosit. Pentru a înregistra fișiere audio și a le salva cu extensia `".wav"` am utilizat Audacity, care este un instrument GUI. Înregistrarea unui fișier se realizează astfel: se

deschide Audacity și se apasă pe butonul de înregistrare (●), iar după ce se termină de rostit mesajul dorit, se apasă butonul de **Stop** (■). Pentru a salva fișierul înregistrat, se selectează din meniul de sus următoarele: **File** → **Export** → **Export as WAV** și se salvează fișierul în folderul proiectului cu numele dorit. [16]

Deoarece este utilizată metoda "recognize_once_async" pentru recunoașterea unei singure secvențe de vorbire, aceasta are o limită maximă de **30 de secunde** pentru fiecare cerere de recunoaștere. După 30 de secunde sau dacă este detectată tăcere, recunoașterea se oprește automat. Astfel, dacă fișierul .wav depășește această durată, doar primele 30 de secunde vor fi transcrise. [12] Pentru fișiere audio mai lungi, am împărțit fișierul în segmente mai mici, folosind metoda "pydub" a bibliotecii "AudioSegment". Pentru a putea utiliza această metodă, am instalat librăria pydub, rulând următoarea comandă în terminal: "pip install pydub". De asemenea, această librărie necesită "FFmpeg" pentru procesarea fișierelor audio. Pașii următori sunt necesari pentru instalarea FFmpeg:

- Descărcarea FFmpeg de la pagina oficială FFmpeg.
- Deschiderea fișierului descărcat și extragerea conținutului arhivei într-un folder.
- Adăugarea căii către binarele FFmpeg în variabila de mediu PATH, astfel: Am deschis Control Panel și am accesat: System → Advanced System Settings → Environment Variables, iar în secțiunea **System Variables**, am editat variabila Path, adăugând calea către folderul bin din directorul în care am extras FFmpeg.
- Verificarea instalării, rulând în terminal comanda "ffmpeg -version". Dacă se afișează versiunea FFmpeg, instalarea este completă. [17]
- După instalarea pydub și configurarea FFmpeg, am rulat din nou scriptul Python.

În continuare, am putut utiliza metoda "pydub" pentru a împărți fișierul în segmente mai scurte, astfel: am convertit timpul în milisecunde, deoarece biblioteca pydub lucrează cu unități de timp exprimate în milisecunde și am ales intervalul de timp dorit, în acest caz de la secunda 0 la secunda 30 (30000 milisecunde) prin linia de cod următoare: "segment = audio[00000:30000]".

4. Rezultate experimentale

În continuare o să prezint câteva exemple de rezultate experimentale obținute în urma testării repetate a aplicației.

În urma preluării semnalului audio **de la microfon**, rezultatele sunt următoarele:

```
PS C:\Users\rusre\Desktop\AzureSpeechProject> python speech_recognition.py
Speak into your microphone.
Recognized: Hello my name is Rebecca, I'm 23 years old and this is my project
PS C:\Users\rusre\Desktop\AzureSpeechProject> |
```

Figura 1. Rezultatul obținut transcrierii semnalului audio în limba engleză

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_RO> python speech_recognition_ro.py
Speak into your microphone.
Recognized: Buna ma numesc Rebeca am 23 de ani și acesta este proiectul meu.
PS C:\Users\rusre\Desktop\AzureSpeechProject_RO> |
```

Figura 2. Rezultatul obținut transcrierii semnalului audio în limba română

În urma preluării semnalului audio **din fișiere cu extensia ".wav"**, rezultatele sunt următoarele:

```
PS C:\Users\rusre\Desktop\AzureSpeechProject> python speech_recognition.py
Recognized: Hello my name is Rebecca, I'm 23 years old and this is my project.
PS C:\Users\rusre\Desktop\AzureSpeechProject> |
```

Figura 3. Rezultatul obținut transcrierii semnalului audio în limba engleză

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Bună mă numesc Rebeca am 23 de ani și acesta este proiectul meu.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 4. Rezultatul obținut transcrierii semnalului audio în limba română, dintr-un fișier înregistrat de mine, folosind "Audacity".

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Mă dusesem să cercetez dacă păstorii noștri aveau grijă *** se cuvine de pășuni, tocmai îmi făceam socotelil e în cort când un cerșetor își vâri capul Pletos înăuntru.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 5. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "53_Continut_Milarepa__Split_.wav"

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Am coborât luându mi arcul și săgețile. Am pus să se deschidă poarta cea mare și l-am ochit.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 6. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "54_Continut_Milarepa__Split_.wav"

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Existau totuși 2 lucruri înlăuntrul meu, care nu slăbeau deloc ura pentru milarepa și teama de moarte milare pa se retrăsese dincolo de orice, ținut locuit într-o peșteră din piatră albă, așezat pe o mică rogojină, aspră stătea î n contemplație cu picioarele legate cu o funie folosită de cei ce meditează și nu se mai hrănea decât cu urzici. Trupul i se scobi precum un schelet și capătă culoarea urzicii până și părul de pe trup i se făcu verde.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 7. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "55_Continut_Milarepa__Split_.wav"

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: De fapt, nu moartea, mă neliniștea o nu ci frica de a pierde tot ce agonisise într-o viață de om turcoazele, vasele de preț Mătăsurile, atlasurile aurul, cerealele, pământurile, păhăruțul meu de Tang. Toate astea aveau să încapă pe alte mâini mâini nepricepute nevolnice odioase, mâini care nu le merita seră moartea era un furt adesea în toiul nop ții mă ridicam în așternut și urlam hoțul prindeți hoțul.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 8. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "56_Continut_Milarepa__Split_.wav"

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Cuprins.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 9. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "cuprins.wav" (au fost preluate primele 30 de secunde ale fișierului)

```
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> python speech_recognition_ro.py
Recognized: Zile de cenușă, 1945 1949, pagina 13.
PS C:\Users\rusre\Desktop\AzureSpeechProject_R0> |
```

Figura 10. Rezultatul obținut transcrierii semnalului audio în limba română, din fișierul denumit "cuprins.wav" (au fost preluate 30 de secunde ale fișierului, însă citirea fișierului se face începând de la secunda 6)

Deoarece metoda "recognize_once_async", utilizată pentru recunoașterea unei secvențe de vorbire, oprește automat recunoașterea în cazul în care detectează tăcere, aplicația nu face transcrierea pentru primele 30 de secunde a fișierelor audio, ci face transcrierea fișierelor până când detectează tăcere. Din acest motiv, în cazul fișierului denumit "cuprins.wav" se face transcrierea doar pentru primul cuvânt (în cazul în care citirea fișierului se face de la secunda 0) sau pentru prima referință din cuprins (în cazul în care citirea fișierului se face începând de la secunda 6 – se elimină primul cuvânt rostit).

5. Concluzii

Aplicația dezvoltată pe baza ghidului **Quickstart: Recognize and convert speech to text** din Microsoft Azure reprezintă o soluție robustă pentru transcrierea în timp real a vorbirii în text, utilizând puterea Azure Cognitive Services. Această aplicație evidențiază beneficiile tehnologiilor de inteligență artificială aplicate în procesarea limbajului natural, fiind capabilă să recunoască vorbirea din diverse surse audio, fie de la microfon, fie din fișiere preînregistrate.

Configurarea și implementarea sa sunt simplificate prin intermediul SDK-ului de la Azure, care permite o integrare ușoară cu limbaje de programare precum Python. Funcționalitatea aplicației este extinsă datorită suportului pentru multiple limbi, ceea ce o face adaptabilă pentru utilizatori din diverse regiuni. Posibilitatea de a schimba limba de transcriere prin simpla modificare a unui parametru din cod, de exemplu din engleză (en-US) în română (ro-RO), demonstrează flexibilitatea platformei.

Aplicația este utilă în numeroase contexte practice, precum crearea de subtitrări, generarea automată a notițelor din întâlniri, accesibilitatea pentru persoane cu dizabilități auditive sau analiza datelor audio. Prin integrarea cu Azure, utilizatorii beneficiază de o securitate sporită, autentificare prin Microsoft Entra ID și posibilitatea de a stoca cheile de acces în locații sigure, cum ar fi Azure Key Vault.

În concluzie, această aplicație reprezintă o implementare puternică și accesibilă a tehnologiei de recunoaștere vocală, fiind ideală pentru utilizatorii care caută o soluție scalabilă, ușor de implementat și adaptabilă pentru diverse scenarii. Cu sprijinul Azure, aplicația oferă o transcriere precisă și unelte avansate pentru a răspunde nevoilor moderne de procesare a vorbirii.

Bibliografie

- [1] Shaip, „Ce este tehnologia Speech-To-Text și cum funcționează în recunoașterea automată a vorbirii,” 16 August 2022. [Interactiv]. Available: <https://ro.shaip.com/blog/automatic-speech-recognition-asr/>. [Accesat 10 Ianuarie 2025].
- [2] L. Paraschiv, „Construiește cu tehnologia Speech-to-Text în Google Cloud,” 24 Mai 2023. [Interactiv]. Available: <https://fotc.com/ro/blog/speech-to-text-google-cloud/>. [Accesat 11 Ianuarie 2025].
- [3] Quora, „What are the advantages and disadvantages of speech to text software?,” 2025. [Interactiv]. Available: <https://www.quora.com/What-are-the-advantages-and-disadvantages-of-speech-to-text-software>. [Accesat 10 Ianuarie 2025].
- [4] E. Urban, A. Orlov, A. Zhao și N. Mehrotra, „What is speech to text?,” 24 Septembrie 2024. [Interactiv]. Available: <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/speech-to-text>. [Accesat 10 Ianuarie 2025].
- [5] Google Cloud, „Turn speech into text using Google AI,” 2025. [Interactiv]. Available: https://cloud.google.com/speech-to-text?utm_source=google&utm_medium=cpc&utm_campaign=emea-ro-all-ro-dr-skws-all-all-trial-e-gcp-1707574&utm_content=text-ad-none-any-DEV_c-CRE_548660712648-ADGP_Hybrid+%7C+SKWS+-+EXA+%7C+Txt+-+AI+And+Machine+Learning+-+Spe. [Accesat 10 Ianuarie 2025].
- [6] Amazon, „Speech to Text Service - Amazon Transcribe,” 2024. [Interactiv]. Available: https://aws.amazon.com/pm/transcribe/?gclid=CjwKCAiA7Y28BhAnEiwAAAdOJUPC8GN150DGLVZYcvm-opU5vfdzLgT1SWdRgPdtP7Shyx428MQ4xjhoCOyMQAvD_BwE&trk=328de7f7-4129-417d-a2f4-ebacfd113537&sc_channel=ps&ef_id=CjwKCAiA7Y28BhAnEiwAAAdOJUPC8GN150DGLVZYcvm-opU5vfdzLgT1SWd. [Accesat 10 Ianuarie 2025].
- [7] Nuance, „Dragon Speech Recognition Solutions,” 2025. [Interactiv]. Available: https://www.nuance.com/dragon.html?srsId=AfmBOorGQE_my2RMXzgCtYq-HSSWVqN8j9g8tdLYBzaNGfr_mv7U8GrL. [Accesat 10 Ianuarie 2025].
- [8] Transkriptor, „Transcrie audio în text,” 2024. [Interactiv]. Available: https://transkriptor.com/ro/discover?utm_source=google-ads&utm_medium=cpc&utm_campaign=TSK%2FRomania%2FRO%2FSearch%2FComputer%2FGeneral&utm_agid=136351553459&utm_adgroup=&utm_term=otter.ai&creative=595493295772&device=c&placement=&targetid=kwd-65080125503. [Accesat 10 Ianuarie 2025].
- [9] Sonix, „Why Sonix,” 2025. [Interactiv]. Available: <https://sonix.ai/>. [Accesat 10 Ianuarie 2025].
- [10] Verbit, „The global leader in transcription & captioning technology,” 2025. [Interactiv]. Available: <https://verbit.ai/>. [Accesat 10 Ianuarie 2025].
- [11] Vatis, „Speech Intelligence Platform to Unlock Audio Potential,” 2025. [Interactiv]. Available: <https://vatis.tech/>. [Accesat 10 Ianuarie 2025].

- [12] E. Urban, S. Gilley, R. Millsap și N. Mehrotra, „Quickstart: Recognize and convert speech to text,” 19 Noiembrie 2024. [Interactiv]. Available: <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/get-started-speech-to-text?tabs=windows%2Cterminal&pivots=programming-language-python>. [Accesat 3 Decembrie 2024].
- [13] Transkriptor, „Cum funcționează Voice-to-Text?,” 25 Iulie 2023. [Interactiv]. Available: <https://transkriptor.com/ro/cum-functioneaza-vocea-in-text/>. [Accesat 11 Ianuarie 2025].
- [14] Azure, „Microsoft Azure,” [Interactiv]. Available: <https://portal.azure.com/#home>. [Accesat 29 Decembrie 2024].
- [15] E. Urban, A. Orlov, S. Baolian, A. Zhao, R. Millsap, A. Jenks, H. Yu și N. Mehrotra, „Language and voice support for the Speech service,” 25 Octombrie 2024. [Interactiv]. Available: <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/language-support?tabs=stt>. [Accesat 3 Decembrie 2024].
- [16] Audacity, „Audacity is the world's most popular audio editing and recording app,” 2025. [Interactiv]. Available: <https://www.audacityteam.org/>. [Accesat 28 Decembrie 2024].
- [17] Audacity Support, „Installing FFmpeg,” 2024. [Interactiv]. Available: <https://support.audacityteam.org/basics/installing-ffmpeg>. [Accesat 12 Ianuarie 2025].